



acreditada
en alta calidad
res. N° 023654 del Mineducación
10/12/21, vigencia 10/12/27

Entrega final - Detección de Empleados sin Casco en Áreas de Trabajo

Presentado por:

Laura Carolina Mateus Agudelo

Andrés Felipe Sainea Rojas

Daniel Antonio Pérez Beltrán

Gerencia de Proyectos para Ciencia de Datos

Te queremos
AQUÍ.

SOMOS LA U. DEL
EMPENDIMIENTO.

Acreditaciones:



Objetivo General

Desarrollar un modelo de reconocimiento de imágenes que identifique automáticamente empleados que no usan casco de seguridad en áreas de trabajo.

Objetivos Específicos

- Recopilar y preprocesar un dataset de imágenes con empleados usando y sin usar casco.
- Entrenar un modelo de machine learning basado en YOLO v11.
- Evaluar la precisión y rendimiento del modelo en escenarios de prueba.

Metodología OSEMN aplicada

Obtener:

- Fuentes de datos, datasets públicos y generación (si es necesario)
- Volumen de datos: Al menos 5000 empleados utilizando y sin utilizar casco.
- Diversidad: Imágenes en diferentes ángulos, iluminación y co



Limpiar:

- Remoción de imágenes borrosas e irrelevantes.
- Etiquetado de imágenes con bounding boxes.
- Balanceo de clases para evitar sesgos en el modelo.




Explorar:

- Análisis exploratorio de datos (EDA): Distribución de imágenes por clases, variables condiciones de iluminación.
- Visualización de datos.




Modelar:

- Utilizando YOLO v11 para detección de objetos.
- Entrenamiento del modelo: Uso de Dataset procesado, evaluación con métricas de precisión, recall y F1-score.



Intepretar:

- Evauación modelo: Confusion matrix, curva ROC, métricas de validación.
- Reporte final.






¿Por qué OSEMN?

Metodología (OSEMN)

Porque ofrece un **flujo práctico y flexible** para proyectos de visión por computadora, abarcando desde la obtención y limpieza de datos hasta su interpretación final. Su carácter iterativo facilita la mejora continua de modelos como YOLO v11, adaptándose mejor que metodologías más generales.



```

└─ datasets/
    └─ train/ # Imágenes y etiquetas para entrenar
        └─ images/
        └─ labels/
    └─ val/ # Imágenes y etiquetas para validación
        └─ images/
        └─ labels/
    └─ test/ # Imágenes y etiquetas para prueba
        └─ images/
        └─ labels/
  
```

Naturaleza de los Datos

- Datos Crudos
- Datos procesados
- Datos Enriquecidos
- Datos de Validacion

Pipeline de Datos



Ingesta y transformación de datos:

- Google Images y datasets públicos [roboflow](https://roboflow.com).
- Eliminación de imágenes corruptas, redimensionamiento a 640x640 píxeles y corrección de etiquetas incorrectas.



Almacenamiento y disponibilidad:

- GitHub
- Google Drive



Plan de monitoreo del pipeline

- Script de validación de etiquetas de las imágenes.
- Evaluación del modelo.

Entrenamiento del modelo

Se utilizo el modelo Yolo nano versión 11 para entrenar el modelo.

```
model = YOLO("yolo11n.pt")
```

```
results = model.train(  
    data="data.yaml",  
    epochs=90,  
    imgsz=640,  
    plots=True,  
    batch=64,  
    lr0=0.0005,  
    optimizer="AdamW",  
    patience=15 )
```



Resultados



Resultados



Análisis de resultados.

Estadísticos

Precision: 0.9429

Recall: 0.9256


F1 - Score: 0.9341

mAP: 0.6902

- Precisión: Un 94.29% de los casos clasificados como positivos realmente pertenecen a la clase correcta.
- Recall: (Sensibilidad) un 92.56% de las instancias reales positivas fueron correctamente identificadas.
- F1-score: F1-score de 93.41% indica un buen equilibrio entre precisión y recall.
- mAP (Mean Average Precision): mAP de ~68% indica que hay margen de mejora en la detección y localización de objetos.

Análisis de resultados.

Matriz de Confusión



Predicciones correctas

- 1,725 casos correctamente identificados como "Sin casco"
- 4,668 casos correctamente clasificados como "casco"

Errores (FN y FP)


FN:

- 28 con casco, se clasificaron como sin casco
- 439 personas con casco no se detectaron.

FP:

- 14 sin casco, se clasificaron como con casco
- 160 sin casco no se detectaron

Análisis de resultados.



- El área de bajo la curva es de 0.91, esto indica que el modelo tiene un excelente desempeño para la tarea de detección de casco.
- La curva se mantiene bien alejada de la diagonal lo que confirma una buena discriminación entre clases.
- En la parte izquierda de la curva (Tasa de Falsos Positivos baja), el modelo mantiene una alta TPR (~0.9), lo cual es positivo.

Conclusiones

El modelo propuesto demuestra su utilidad en la detección automatizada de empleados sin casco, lo que se traduce en un avance para la seguridad laboral y prevención de accidentes. Los resultados obtenidos, con una F1-score por encima del 90%, validan el enfoque adoptado. No obstante, es importante mencionar ciertas áreas de oportunidad:

- Ampliación del Dataset: Recoger más imágenes y situaciones distintas (entornos nocturnos, diferentes tipos de casco, industrias variadas) para robustecer la red.
- Optimización del Modelo: Evaluar la implementación de versiones más ligeras de YOLO o aplicar técnicas como pruning y cuantización, especialmente para la ejecución en dispositivos de bajo rendimiento.
- Refinamiento en el Postprocesamiento: Explorar algoritmos avanzados de filtrado para reducir falsos positivos, particularmente en entornos llenos de objetos similares al casco.